

ML 模型部署 — 问答问题集 (Q&A)

ML 模型部署 — 问答问题集 (Q&A)

配套文档: ml-deploy.md 难度分层: 事实型 | 理解型 | 应用型**配套文档**: `ml-deploy.md`
难度分层: 事实型 | 理解型 | 应用型
配套文档: ml-deploy.md 难度分层: 事实型 | 理解型 | 应用型
配套文档: `ml-deploy.md`
难度分层: 事实型 | 理解型 | 应用型

事实型问题事实型问题

- Q1: 五种 ML 部署模式分别是什么? 延迟最低的是哪种?
Q2: MLOps 成熟度分为哪四级?
Q3: 模型导出 ONNX 格式有什么优势?
Q4: 四种量化方法中, 哪一种精度损失最低?
Q5: MLOps 中模型阶段从 Staging 转换到 Production 意味着什么?

理解型问题理解型问题

- Q6: 为什么嵌入式模型 (ONNX/TensorRT) 推理延迟最低但成本标注为"低"?
Q7: 动态量化、静态量化、QAT 三者的区别和适用场景是什么?
Q8: 为什么文档强调"预处理 pipeline 一致性"是推理结果不一致的常见原因?

应用型问题应用型问题

- Q9: TensorFlow 模型需要部署到不支持 TensorFlow 的边缘设备上怎么办?
Q10: 模型发布前需满足哪些条件? 准确率 > 90% 持续 10 天才能部署吗? 但模型刚部署时流量少怎么办?
Q11: 灰度发布策略中 Beta 版本的流量是 10% 还是 5%? 如何动态调整?
Q12: 数据漂移检测发现 $p=0.003$ (< 0.01), A/B 测试显示模型准确率从 94% 降到 89%。但业务人员说现在输入数据分布确实变了 (新市场用户)。怎么办?

自信度评级: 事实型 95%+ | 理解型 85%+ | 应用型 80%+**自信度评级**: 事实型 95%+ | 理解型 85%+ | 应用型 80%+
自信度评级: 事实型 95%+ | 理解型 85%+ | 应用型 80%+**自信度评级**: 事实型 95%+ | 理解型 85%+ | 应用型 80%+